


Schéma de données — Pipeline multimodal CheckItAI

Étape 3 — modèle conceptuel des données transformées

Ce document décrit le modèle **conceptuel** des données produites par le pipeline de transformation. Il se place au niveau métier (entités, attributs, relations, rôle dans le cas d’usage IA) et **non** au niveau technique (pas de tables SQL, d’index ni de clés physiques).

Diagramme conceptuel



Description des champs

Chaque champ est rattaché à un **rôle** dans le cas d'usage de détection de fake news : entrée du modèle (NLP / Vision), cible d'apprentissage, feature dérivée, ou métadonnée.

Champ	Type	Rôle dans le cas d'usage IA
id	string	Identifiant unique, sert à la déduplication
texte	string	Entrée NLP : texte nettoyé analysé par le modèle de langage
url_image	string	Entrée Vision : lien vers l'image associée, validé par le pipeline
date	datetime (ISO 8601)	Métadonnée temporelle (fraîcheur, tri, traçabilité)
label	string null	Cible de classification vrai/faux — vide pour NewsData.io (pas de vérité terrain)
text_length	int	Feature dérivée : longueur du texte (filtrage des contenus trop courts)
has_image	boolean	Feature dérivée / contrôle qualité : confirme la présence d'une image valide
url_article	string	Métadonnée : lien vers la publication d'origine
langue	string	Métadonnée : langue, utile au filtrage et au choix du modèle
auteur	string	Métadonnée : auteur ou compte émetteur

Entité SOURCE

Champ	Type	Rôle
source	string	Nom de la source de données (ex. <code>newsdata.io</code>)
domaine	string	Nom de domaine émetteur — signal de fiabilité pour le modèle

Lien texte ↔ image

Le point central du projet est garanti par construction : **texte et image vivent dans la même entité PUBLICATION**. Une entrée n'est conservée que si `texte` et `url_image` sont tous deux valides (champ `has_image` = `true`). Il n'existe donc

aucune publication orpheline (texte sans image ou image sans texte) dans les données finales.

Relation SOURCE → PUBLICATION

Une source produit plusieurs publications (relation 1 à plusieurs). Cette séparation conceptuelle distingue ce qui caractérise **l'émetteur** (nom, domaine, fiabilité) de ce qui caractérise **la publication** (texte, image, date). Dans les données plates exportées en JSON, ces informations cohabitent dans chaque entrée ; le modèle conceptuel met en évidence leur nature différente.